

Ταξινόμηση όγκων στο μαστό μέσω Ιστοπαθολογικής Εικόνας και Βαθιάς Μάθησης

Georgios Batsis

July 2, 2022

1 Εισαγωγή

Ο καρκίνος του μαστού είναι μία από τις συχνότερα διαγνωσμένες κακοήθειες χυρίως στις γυναίκες, καταλήγοντας να είναι υπεύθυνος για το 15% των καταγεγραμμένων περιπτώσεων θανάτου από καρκίνο στις γυναίκες. Οι συγκεκριμένοι όγκοι ανιχνεύονται σε πρώτη φάση μέσω τεχνικών ψηλάφησης και εν συνεχείᾳ μέσω διαγνωστικών εξετάσεων βασισμένες σε εικόνες, όπως οι υπέρηχοι ή η μαστογραφία. Σε περίπτωση διάγνωσης όγκου, ακολουθείται η διαδικασία της βιοψίας με σκοπό την ταξινόμηση σε καλοήθη ή καρκινικό όγκο [1, 2]. Η ανάλυση ιστοπαθολογικών δεδομένων με σκοπό την ταξινόμηση του καρκινώματος του βασίζεται συνήθως στην ερμηνεία μορφολογικών χαρακτηριστικών των όγκων. Η απόδοση στην ταξινόμηση των όγκων εξαρτάται αποκλειστικά από τις γνώσεις και την εμπειρία των παθολογοανατόμων που καλούνται να αξιολογήσουν τέτοιο είδους εξετάσεις. Η εν λόγω αξιολόγηση απαιτεί χρόνο διότι αφενός η μορφολογία και πυκνότητα του ιστού διαφέρει από άνθρωπο σε άνθρωπο, αφετέρου οι ιστολογικές εικόνες αναλύονται με την χρήση διαφόρων επιπέδων μεγέθυνσης [3].

Μεγάλο μέρος μηχανικών και επιστημόνων θεωρούν ότι η έρευνα και ανάπτυξη μεθόδων υπολογιστικής διάγνωσης αποτελούν τον βασικό μοχλό διευκόλυνσης των γιατρών. Η διάγνωση βάσει υπολογιστικών συστημάτων βασίζεται σε τεχνικές Ψηφιακής Επεξεργασίας Εικόνας και αλγορίθμους Τεχνητής Νοημοσύνης. Αφετηρία για την νέα εποχή στην ιατρική γνωμάτευση αποτέλεσε η εφαρμογή μεθόδων εξαγωγής χαρακτηριστικών, όπως είναι τα χαρακτηριστικά υφής ή η εφαρμογή φίλτρων και εν τέλει ο συνδυασμός τους με ταξινομητές όπως Support Vector Machines ή Naive Bayes. Η έλευση, όμως, της Βαθιάς Μηχανικής Μάθησης μείωσε αισθητά την ανάγκη εφαρμογής αλγορίθμων Ψηφιακής Επεξεργασίας Εικόνας, καθώς τα απαραίτητα για την ταξινόμηση χαρακτηριστικά εξάγονται από τα Βαθιά Νευρωνικά Δίκτυα. Η διαδικασία ανάπτυξης, όμως, των τελευταίων προϋποθέτει την αξιοποίηση ενός μεγάλου όγκου δεδομένων τα οποία είναι διαθέσιμα στην επιστημονική κοινότητα. Θεωρείται ότι στην διάγνωση του καρκίνου χρησιμοποιώντας εικόνες καρκινικών ιστών τα Βαθιά Νευρωνικά Δίκτυα επιτυγχάνουν αποδόσεις μεγαλύτερες από τους γιατρούς

της αντίστοιχης ειδικότητας [4]. Επομένως, ο συνδυασμός εξελιγμένων μεθόδων υπολογιστικής διάγνωσης και της γνώσης και εμπειρίας των γιατρών αποτελεί μια υποσχόμενη πρακτική για το μέλλον των ασθενών.

Η διάγνωση του καρκίνου του μαστού πραγματοποιείται αρχικά με τον εντοπισμό του όγκου σε μαστογραφίες και το συγκεκριμένο είδος εικόνων είναι από τα κύρια με τα οποία οι βιοϊατρικοί μηχανικοί μελετούν. Στις δημοσιεύσεις [5, 6] αναπτύσσονται Βαθιά Νευρωνικά Δίκτυα εκπαιδευμένα δε ολόκληρες μαστογραφίες με σκοπό την ταξινόμηση και τον χαρακτηρισμό της περιοχής του όγκου (Segmentation). Όπως προαναφέρθηκε, αφετηρία για την ανάλυση ιστοπαθολογικών εξετάσεων αποτελεί η εξαγωγή μορφολογικών χαρακτηριστικών με σκοπό τον εντοπισμό της κακοήθειας. Συγκεκριμένα, στην Εργασία [7] εξάγεται πληροφορία για το τμήμα της επιφάνειας που καταλαμβάνει ο όγκος στα κύτταρα, το σχήμα του και της αρίθμηση των επεκτάσεων αυτού. Πλέον, αυτά τα χαρακτηριστικά εξάγονται αυτόματα από Βαθιά Νευρωνικά Δίκτυα, είτε πρόκειται για τις πρωτοεμφανιζόμενες αρχιτεκτονικές όπως το AlexNet και το VGG 16 [7] ή αφορά πιο προηγμένα δίκτυα όπως το Inception V3 [8].

Στην συγκεκριμένη εργασία, αναπτύσσεται ένα Βαθύ Νευρωνικό Δίκτυο με σκοπό την ταξινόμηση ιστοπαθολογικών εικόνων. Το μοντέλο εκπαιδεύεται σε εικόνες τεσσάρων διαφορετικών επιπέδων μεγέθυνσης με σκοπό την αύξηση της διακριτικής ικανότητας ανά ασθενή. Η αρχιτεκτονική του δικτύου αναπτύχθηκε βάση του μοντέλου MobileNet ακολουθούμενο από έναν ταξινομητή που αποτελείται από στρώματα πλήρως συνδεδεμένων νευρώνων (Fully Connected - FC Layer). Το δίκτυο επιλέχθηκε λόγω της ταχύτητας με την οποία εκτελεί προβλέψεις. Η αξιολόγηση του μοντέλου πραγματοποιείται, πέραν των παραδοσιακών μετρικών, με μια μετρική η οποία προτείνεται στην δημοσίευση που σχετίζεται με το σύνολο δεδομένων (Dataset).

Η εργασία οργανώνεται στις εξής ενότητες: Στην Ενότητα 2 παρουσιάζονται οι βασικές μέθοδοι που χρησιμοποιούνται. Στην Ενότητα 3 αναλύεται η μεθοδολογία που προτείνεται. Στην Ενότητα 4 παραθέτονται τα αποτελέσματα. Η τελευταία ενότητα αφορά τα συμπεράσματα.

2 Μέθοδοι

2.1 Συνελικτικά Νευρωνικά Δίκτυα

Τα τελευταία χρόνια, τα Συνελικτικά Νευρωνικά Δίκτυα (Convolutional Neural Networks - CNNs) έχουν συμβάλλει στην ανάπτυξη σημαντικών εφαρμογών στον τομέα της Μηχανικής Όρασης, όπως η ταξινόμηση εικόνων και ο εντοπισμός αντικειμένων. Τα CNN εχουν ως βασικό δομικό στοιχείο στρώματα (Layers) τα οποία υπολογίζουν συνελίξεις μεταξύ εικόνας και φίλτρων. Τα CNN αποτελούνται από πολλά Layers οπου στο πρώτο εκτελείται συνέλιξη μεταξύ εικόνας και φίλτρου και το αποτέλεσμα μεταφέρεται στα πιο βαθιά Layers και η διαδικασία της συνέλιξης επαναλαμβάνεται. Το αποτέλεσμα της συγκεκριμένης μαθηματικής πράξης αποκαλείται χάρτης χαρακτηριστικών (Feature Maps). Σε κάθε επίπεδο

χρησιμοποιούνται πολλαπλά φίλτρα, τα βάρη των οποίων διαμορφώνονται κατά την διαδικασία εκπαίδευσης. Η διαδικασία αυτή αντικατέστησε την παραδοσιακή εξαγωγή χαρακτηριστικών. Στα τελευταία Layers τοποθετείται ένας Fully Connected ταξινομητής με σκοπό την κατηγοριοποίηση της εικόνας στην είσοδο [9].

2.2 Μεταφορά Μάθησης

Η μέθοδος Μεταφοράς Μάθησης (Transfer Learning) διάσημων αρχιτεκτονικών DNN, όπως για παράδειγμα προ-εκπαίδευμένα CNN σε μεγάλου εύρους Datasets σαν το ImageNet, έχει αποδειχτεί ότι αποτελεί αποτελεσματική προσέγγιση ενός προβλήματος για το οποίο είτε δεν υπάρχουν αρκετά δεδομένα ώστε η εκ του μηδενός εκπαίδευση να οδηγήσει σε ένα μοντέλο υψηλών επιδόσεων ή όταν είναι αναγκαία μια εναλλακτική και συγχρόνως αποδοτική μέθοδο εξαγωγής χαρακτηριστικών. Χαρακτηριστική ιδιότητα των μοντέλων που έχουν εκπαιδευτεί σε Datasets μεγάλου αριθμού κλάσεων είναι η υψηλή διακριτική ικανότητα η οποία συνεπάγεται την δυνατότητα εξαγωγής χρήσιμης πληροφορίας. Επομένως, καθίστανται ένα ισχυρό εργαλείο στην διαχείρισης δεδομένων μικρότερου μεγέθους ακόμη και αν αυτά ανήκουν σε διαφορετικό πεδίο εφαρμογών από το αντίστοιχο της αρχικής εκπαίδευσης [10].

3 Προτεινόμενη Μέθοδος

Στην παρούσα εργασία υλοποιήθηκε ένα CNN ταξινόμησης ιστοπαθολογικών εικόνων όγκων στο μαστό ως καλοήθεια ή κακοήθεια. Πρόκειται, δηλαδή, για πρόβλημα δυαδικής ταξινόμησης. Το σύστημα υλοποιήθηκε με σκοπό την προσάρτησή του σε εφαρμογή ψηφιακής διάγνωσης ιστοπαθολογικών εικόνων πολλαπλών επιπέδων μεγέθυνσης, αφού ο ειδικός μπορεί να εισάγει ολόκληρη της εικόνα η οποία τεμαχίζεται σε πλακίδια (Tiles) και ύστερα εισέρχεται στο CNN. Συστήνεται, δηλαδή, η πλήρης διάγνωση για κάθε ασθενή μεμονωμένα. Τα βήματα της μεθοδολογίας στην γενική περίπτωση φαίνονται στην Εικόνα 1.

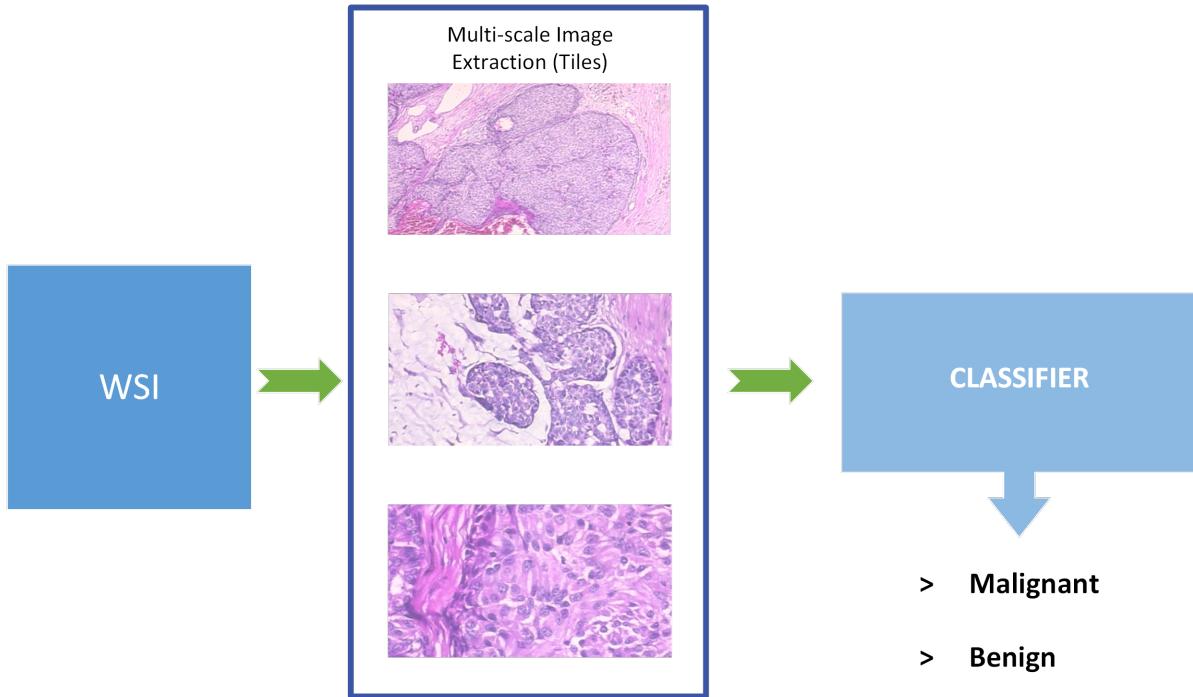


Figure 1: Βασικά βήματα μεθοδολογίας υπολογιστικής διάγνωσης με την χρήση ιστοπαθολογικών εικόνων και Τεχνητής Νοημοσύνης

Η αρχιτεκτονική του δίκτυου βασίζεται στο μοντέλο MobileNet v2 της Google [11]. Η λογική πίσω από την δημιουργία του συγκεκριμένου CNN είναι η δυνατότητα ενσωμάτωσης σε κινητές υπολογιστικές μονάδες οι οποίες δεν διαθέτουν GPU. Η αύξηση της ταχύτητας του δίκτυου προήλθε από τον διαχωρισμό των παραδοσιακών συνελίξεων σε επιμέρους κατά βάθος. Με αυτόν τον τρόπο δεν μειώνεται μόνο ο χρόνος ανάπτυξης, αλλά και η ανάγκη υπολογιστικής ισχύς λόγω της μείωσης των παραμέτρων εκπαίδευσης. Η ανάγκη, λοιπόν, που υπάρχει για ταχύτερες ιατρικές διαγνώσεις, μας οδήγησε στην χρήση ενός ευέλικτου CNN σαν το MobileNet.

Όπως αναφέρεται και στην προηγούμενη Ενότητα, η μέθοδος Transfer Learning λειτουργεί αποδοτικά ακόμα και όταν η διεργασία ανήκει σε άλλον τομέα από αυτόν στα δεδομένα του οποίου το δίκτυο έχει προ-εκπαίδευτεί. Επομένως, αρχικοποιούμε το MobileNet με τα βάρη του ImageNet, αφαιρώντας το Layer ταξινόμησης. Στην συνέχεια προσθέτουμε ένα Fully Connected Layer που αποτελείται από δύο χρυφά επίπεδα 2048 και 512 Νευρώνων. Η εξόδος του δίκτυου είναι ένας νευρώνας με την συνάρτηση ενεργοποίησης sigmoid που χρησιμοποιείται σε προβλήματα δυαδικής ταξινόμησης. Τα βάρη του MobileNet τροποποιούνται κατά την διαδικασία εκπαίδευσης μαζί με τα βάρη του Fully Connected Layer (End-to-End Training). Το τελικό δίκτυο παρουσιάζεται στην Εικόνα 2.

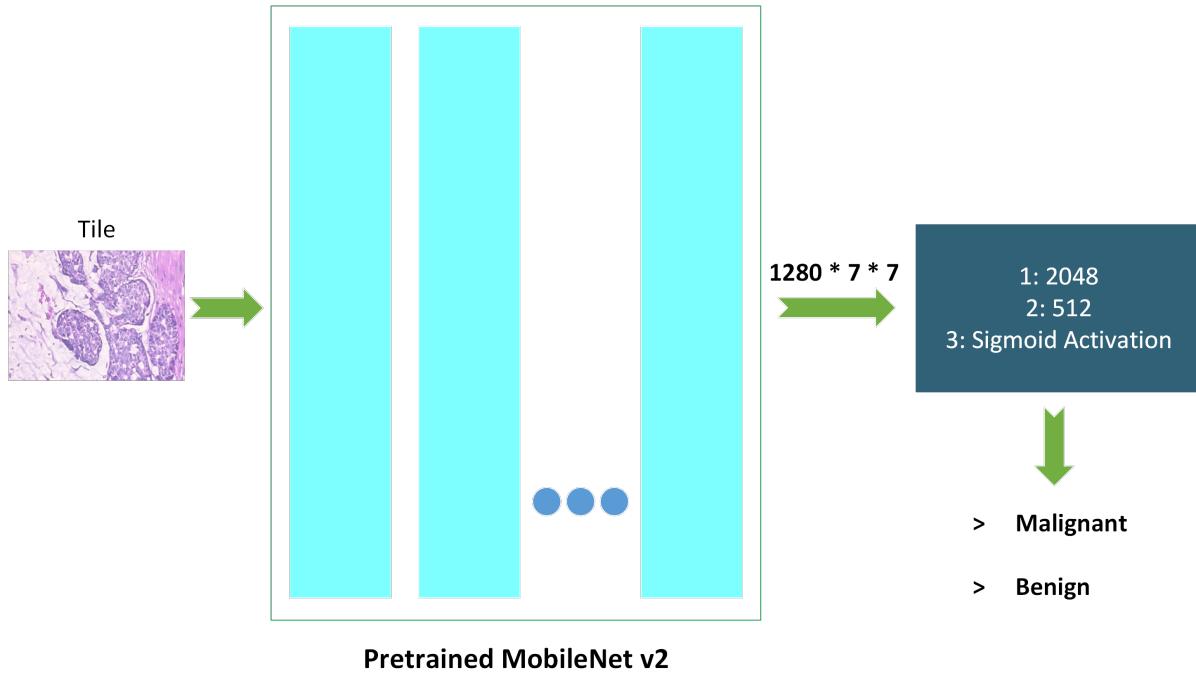


Figure 2: Αρχιτεκτονική Νευρωνικού Δικτύου

4 Αποτελέσματα

4.1 Σύνολο Δεδομένων και προ-επεξεργασία

Τα πειράματα εκτελέστηκαν λαμβάνοντας τις διαθέσιμες εικόνες της βάσης δεδομένων Breast Cancer Histopathological (BreakHis) που αναφέρεται στην επιστημονική δημοσίευση [12] σε συνεργασία με το εργαστήριο P&D - Pathological Anatomy and Cytopathology που εδρεύει στην πολιτεία Παρανά της Βραζιλίας. Το Dataset αποτελείται από 7909 ιστοπαθολογικές εικόνες που αντιστοιχούν σε 82 ασθενείς και είναι άμεσα διαθέσιμο (<http://web.inf.ufpr.br/vri/breast-cancer-database> ή στο Kaggle <https://www.kaggle.com/datasets/ambarish/breakhis>). Ακολουθείται ιεραρχική κατανομή των εικόνων αρχικά ανά κατηγορία όγκου, εν προκειμένω καλοήθεια ή κακοήθεια και ύστερα οι εικόνες κατατάσσονται σε υπο-κατηγορίες καρκινώματος. Για κάθε ασθενή, οι εικόνες διατίθενται σε τέσσερα επίπεδα μεγέθυνσης: 40X, 100X, 200X, 400X. Οι ερευνητές που συγκέντρωσαν τα δεδομένα πειραματίστηκαν και με μοντέλα ταξινόμησαν εικόνων, επιτυγχάνοντας απόδοση 80-85%.

Προκειμένου να αναπτύξουμε το προτεινόμενο CNN χρειάστηκε να διαμερίσουμε το Dataset σε τρία βασικά μέρη: Εκπαίδευσης, επαλήθευσης και ελέγχου (Train, Validation, Test). Ο διαμερισμός πραγματοποιήθηκε σε επίπεδο ασθενών, ώστε να εξασφαλιστεί η ανθεκ-

τικότητα (Robustness) του μοντέλου σε εντελώς άγνωστα δεδομένα. Επιπλέον, βασικά βήματα προ-επεξεργασίας αποτέλεσαν η διαφοροποίηση του μεγέθους της εικόνας σε 224x224 που βρίσκενται εντός του εύρους απαιτήσεων του MobileNet και η κανονικοποίηση των τιμών των pixel σε συγκεκριμένο εύρος. Τέλος, εφαρμόστηκε η τεχνική Data Augmentation με μεθόδους Horizontal Flip και Rotate 30 μοιρών στο Training μέρος προκειμένου να αυξηθεί ο αριθμός των δεδομένων εκπαίδευσης και άρα να αυξηθεί η απόδοση του CNN και να αποφευχθεί ο κίνδυνος του Overfitting. Στην Εικόνα 3 παρουσιάζεται δείγμα από το BreakHis dataset με τις εικόνες να διατάσσονται ανά κατηγορία όγκου και υπο-κατηγορία χαρκινώματος.

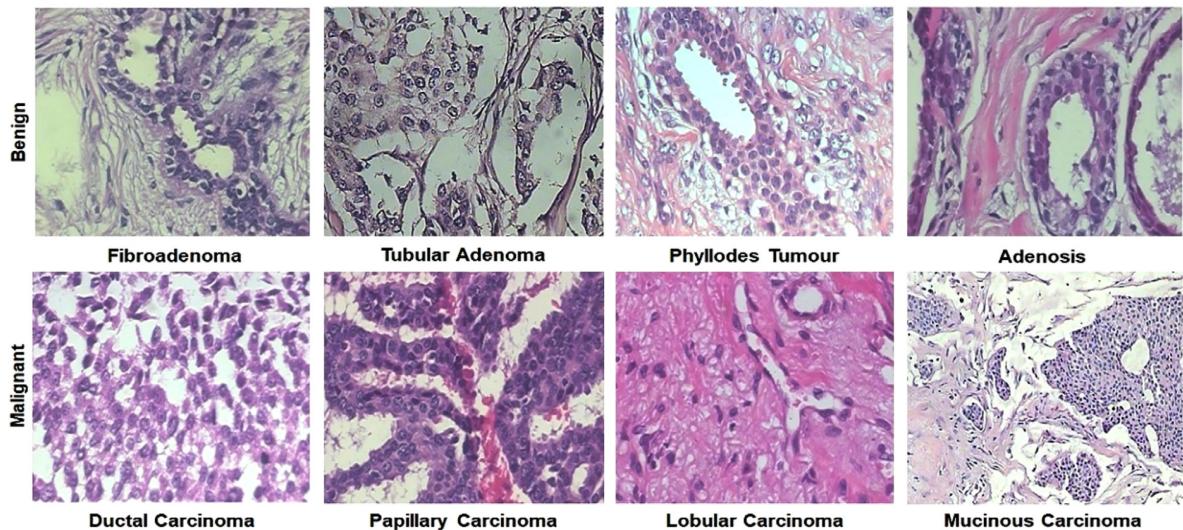


Figure 3: Παράδειγμα από το BreakHis Dataset. Η εικόνα δημοσιεύτηκε στην Εργασία [13].

4.2 Συνάρτηση απωλειών και Μετρικές απόδοσης

Η βελτιστοποίηση του μοντέλου βασίστηκε στην συνάρτηση απωλειών (Loss Function) Binary Cross - Entropy (BCE), η οποία δέχεται την πραγματική κλάση ενός δείγματος και την πιθανότητα που προβλέψθηκε για κάθε κλάση:

$$BCE = -(y \log(p) + (1 - y) \log(1 - p))$$

Η απόδοση του μοντέλου μετράται με την βοήθεια των παρακάτω μετρικών οι οποίες βασίζονται στις ορθές και λανθασμένες προβλέψεις:

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

$$Precision = \frac{TP}{TP+FP}$$

$$Recall = \frac{TP}{TP+FN}$$

$$F1 = \frac{2*Precision*Recall}{Precision+Recall} = \frac{2*TP}{2*TP+FP+FN}$$

Στην δημοσίευση του BreakHis, προτείνονται από τους δημιουργούς δύο ακόμη μετρικές που αντικατοπτρίζουν τις σωστές προβλέψεις του εκάστοτε μοντέλου σε επίπεδο ασθενών. Συγχεκριμένα, αν N_{rec} είναι οι σωστές προβλέψεις για κάθε μεμονωμένο ασθενή και N_P το σύνολο των εικόνων που αντιστοιχεί σε αυτόν, τότε η απόδοση ανά ασθενή (Patient Score) διαμορφώνεται ως εξής:

$$PatientScore = \frac{N_{rec}}{N_P}$$

Ενώ το μέσο Patient Score αντιστοιχεί στην μετρική ρυθμού αναγνώρισης (Recognition Rate):

$$RecognitionRate = \frac{\sum(PatientScore)}{Number\,of\,Patients}$$

4.3 Εκπαίδευση μοντέλων και έλεγχος ορθότητας

Η ανάπτυξη των CNN συμπεριλαμβανομένης της εκπαίδευσης και του ελέγχου ορθότητας πραγματοποιήθηκαν σε Python με την χρήση της βιβλιοθήκης scikit-learn και του PyTorch Framework. Η παρακολούθηση των μετρικών απόδοσης όσο διαρκούσαν οι εποχές έγινε με την βιόμηση του Tensorboard. Για την εκπαίδευση υέσαμε ως μέγιστο αριθμό εποχών τις 100 αλλά με συνθήκη πρόωρης διακοπής εκπαίδευσης (Early Stopping) σε περίπτωση που το Loss στο Validation μέρος των δεδομένων δεν βελτιωνόταν περαιτέρω για 5 συνεχόμενες εποχές (Patience). Ως optimizer χρησιμοποιήθηκε ο Adam ενώ το μέγεθος κάθε batch ορίστηκε στα 8. Τα πειράματα έλαβαν χώρα σε τοπικό υπολογιστικό σύστημα με GPU NVIDIA RTX 2060 και στην υπηρεσία Cloud Computing Kaggle kernels - notebooks με την υποστήριξη GPU.

Στην Εικόνα 4 παρουσιάζονται οι καμπύλες εκπαίδευσης. Αριστερά βρίσκεται η εξέλιξη της μετρικής F1, ενώ στα δεξιά της BCE. Η πορτοκαλί καμπύλη αντιπροσωπεύει τα δύο μεγέθη για το Training μέρος των δεδομένων, ενώ η μπλε για το Validation. Παρατηρείται ότι μετά την εποχή 13 το μοντέλο αποθηκεύεται και εν συνεχείᾳ δεν εξελίσσεται περαιτέρω με αποτέλεσμα η εκπαίδευση να σταματήσει στην εποχή 15. Το μοντέλο επιτυγχάνει υψηλές επιδόσεις όσον αφορά το Validation μέρος στον συνολικό αριθμό εικόνων. Επιπλέον, η διαδικασία εκπαίδευσης ολοκληρώθηκε στις δύο ώρες και αν λάβουμε υπόψιν μας ότι χρησιμοποιήθηκε μέγεθος εικόνας 224x224 και ότι το δίκτυο εκπαιδεύτηκε End-To-End, τότε πρόκειται για σημαντικά μικρή χρονική πολυπλοκότητα.

Results: Training Curves

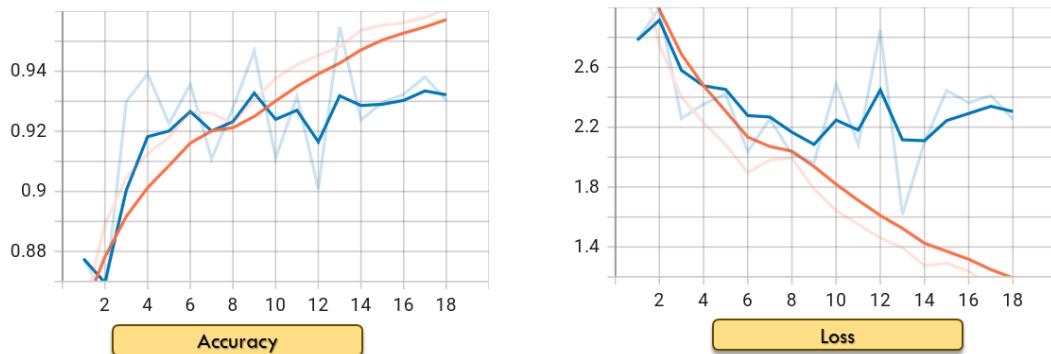


Figure 4: Καμπύλες Εκπαίδευσης. Αριστερά παρουσιάζεται η εξέλιξη της μετρικής F1, ενώ στα δεξιά της BCE. Η πορτοκαλί καμπύλη αντιπροσωπεύει τα δύο μεγέθη για το Training μέρος των δεδομένων, ενώ η μπλε για το Validation.

Ανακαλώντας το στιγμιότυπο του CNN (Model State) τα βάρη του οποίου αποθηκεύτηκαν όταν σημείωσε την μικρότερη τιμή του Validation BCE (εποχή 13), πραγματοποιήσαμε προβλέψεις στο Test μέρος των δεδομένων. Οι προβλέψεις, αρχικά, αφορούσαν το σύνολο των εικόνων και η αναλυτική αποδοση της ταξινόμησης (Classification Report) παρατίθεται στην Εικόνα ???. Ο ακριβής αριθμός σωστών και λανθασμένων προβλέψεων παρουσιάζεται στον παρακάτω πίνακα (Confusion Matrix):

True\Predicted	Benign	Malignant
Benign	515	33
Malignant	105	851

	precision	recall	f1-score	support
0	0.83	0.94	0.88	548
1	0.96	0.89	0.93	956
accuracy			0.91	1504
macro avg	0.90	0.91	0.90	1504
weighted avg	0.91	0.91	0.91	1504

Figure 5: Αποτελέσματα προβλέψεων στο σύνολο των εικόνων του Test Dataset

Σύμφωνα με τα παραπάνω αποτελέσματα, το μοντέλο που δημιουργήθηκε είναι αξιόπιστο και επιτυγχάνει πιο υψηλή απόδοση από τα αντίστοιχα που χρησιμοποίησαν οι δημιουργοί του Dataset (Baseline). Η πραγματική, όμως, αξιοπιστία αποτυπώθηκε όταν προχωρήσαμε στον υπολογισμό των μετρικών σε επίπεδο ασθενών, εν προκειμένω των μετρικών Patient Score και Recognition Rate. Αρχικά, υπολογίστηκε το πρώτο μέγεθος που αντιστοιχεί στο ποσοστό των σωστών προβλέψεων ανά ασθενή. Η αναλυτική παρουσίαση των αποτελεσμάτων απεικονίζεται στα εξής γραφήματα: Στην Εικόνα 6 όπου συγχρίνεται ο αριθμός σωστών προβλέψεων (πράσινο γράφημα) με τον συνολικό αριθμού εικόνων ανά ασθενή (μπλε γράφημα) και στην Εικόνα 7 όπου παρουσιάζεται η μετρική Patient Score. Σε σύνολο 17 ασθενών που αντιστοιχούν οι εικόνες του Test Dataset, το μοντέλο μόνο για έναν ασθενή επιτυγχάνει Patient Score μικρότερο του 50% που αντιστοιχεί στην τυχαία επιλογή, ενώ στην πλειοψηφία των ασθενών επιτυγχάνεται απόδοση άνω του 80% και μάλιστα για τους 8 το μοντέλο προβλέπει σωστά όλες τις εικόνες. Εν κατακλειδί, η τελική τιμή της μετρικής Recognition Rate διαμορφώνεται στο 90%. Ο συγκεκριμένος αριθμός αποτελεί, σύμφωνα με τους δημιουργούς του Dataset, την ουσιαστική απόδοση του μοντέλου αφού αντικατοπτρίζει την αναγνώριση της νόσου σε επίπεδο ασθενών.

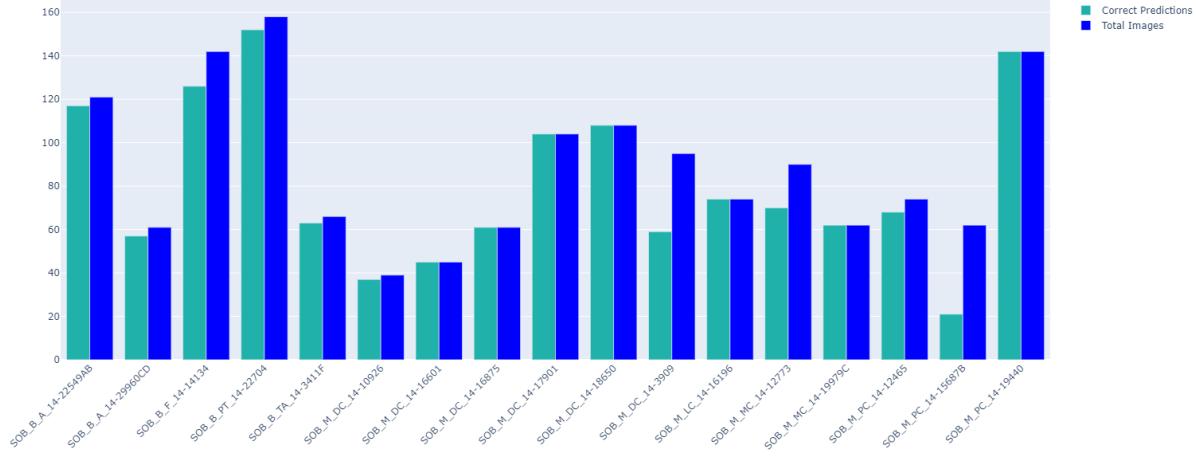


Figure 6: Αριθμός σωστών προβλέψεων και συνολικού αριθμού εικόνων ανά ασθενή. Το πράσινο γράφημα αντιστοιχεί στις σωστές προβλέψεις, ενώ το μπλε στο σύνολο των εικόνων.

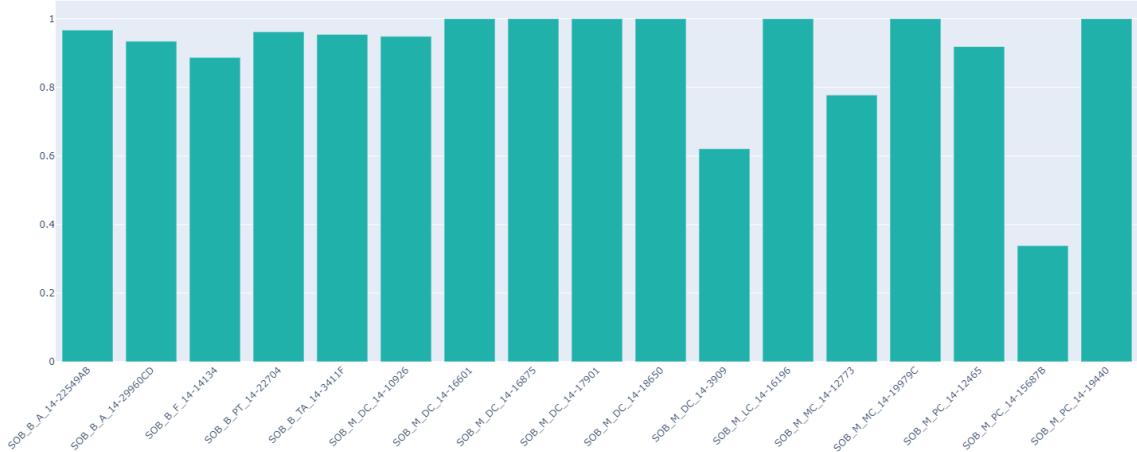


Figure 7: Μετρική Patient Score

5 Συμπεράσματα

Ο καρκίνος του μαστού αποτελεί μια εκ των συχνότερων και βλαβερότερων μορφών καρκίνου ιδιαίτερα για τον γυναικείο πληθυσμό. Γι αυτόν τον λόγο, η αυτοματοποίησης του εντοπισμού, της ανάλυσης και της κατηγοριοποίησης του αποτελούν πρόκληση για την επιστη-

μονική κοινότητα. Οι τεχνικές Ψηφιακής Επεξεργασίας Εικόνας και οι αλγόριθμοι Βαθιάς Μηχανικής Μάθησης διαδραματίζουν κομβικό ρόλο στην εξέλιξη και αυτοματοποίηση των προαναφερθέντων διεργασιών. Δεν υπάρχει αμφιβολία, ότι ο ερχομός νέων μοντέλων ταξινόμησης εικόνων που χαρακτηρίζονται από υψηλές επιδόσεις και ικανότητες γενικοποίησης μεταξύ προβλημάτων, θα δημιουργήσει μια νέα διάσταση στην υπολογιστική ιατρική διάγνωση και στις εφαρμογές βιοϊατρικής. Στην συγκεκριμένη εργασία αναπτύχθηκε ένα CNN το οποίο πέραν της αξιοπιστίας του και της σημαντικά υψηλής απόδοσής του, χαρακτηρίζεται και από ευελιξία λόγω της ταχύτητας υπολογισμών της αρχιτεκτονικής MobileNet. Αξίζει να σημειωθεί ότι το CNN εκπαιδεύτηκε στο να ταξινομεί τις εικόνες σε κακοήθεις ή καλοήθεις όγκους, χρησιμοποιώντας ένα Dataset με δύο βασικά χαρακτηριστικά: την διαθεσιμότητα των ιστοπαθολογικών εικόνων σε πολλαπλά επίπεδα μεγέθυνσης και την δυνατότητα διαχωρισμού σε επίπεδο ασθενών. Η αξιολόγηση του μοντέλου πραγματοποιήθηκε τόσο μέσω μετρικών ταξινόμησης όπως Precision, Recall και F1 Score, όσο και μέσω μετρικών ειδικά διαμορφωμένων για προβλήματα ιατρικών διαγνώσεων, εν προκειμένω Patient Score και Recognition rate όπως προτείνονται στην επιστημονική δημοσίευση του Dataset. Ο ταξινομητής που αναπτύχθηκε επιτυγχάνει F1 Score 91% και Recognition Rate 90% σε επίπεδο ασθενών. Μελλοντικά στην ιατρική διάγνωση μέσω αλγορίθμων Βαθιάς Μάθησης μπορούν να δημιουργηθούν μοντέλα τα οποία να εκπαιδευτούν και να επαληθευτούν μεταξύ πολλαπλών Datasets, δοκιμάζοντας δηλαδή της ικανότητα γενικοποίησης. Επιπλέον, είναι δυνατόν να αναπτυχθούν CNN που να συνδυάζουν διαφορετικούς τύπους δεδομένων (Multi-modal CNNs) όπως για παράδειγμα ταυτόχρονη διάγνωση μέσω εικόνων μαστογραφίας και υπερήχου ή ιστοπαθολογικών εικόνων. Τέλος, σημαντικό ρόλο θα διαδραματίσουν και τα καινοτόμα μοντέλα Vision Transformers που βασίζονται στον μηχανισμό Attention ο οποίος ήταν ο βασικός μηχανισμός στην υλοποίηση γλωσσικών μοντέλων.

References

- [1] A. A. A. Figueiredo, J. G. do Nascimento, F. C. Malheiros, L. H. da Silva Ignacio, H. C. Fernandes, and G. Guimaraes, “Breast tumor localization using skin surface temperatures from a 2d anatomic model without knowledge of the thermophysical properties,” *Computer methods and programs in biomedicine*, vol. 172, pp. 65–77, 2019.
- [2] N. Dongola, “Mammography in breast cancer,” *MedScape*, 2018.
- [3] M. Jannesari, M. Habibzadeh, H. Abulkheyr, P. Khosravi, O. Elemento, M. Totonchi, and I. Hajirasouliha, “Breast cancer histopathological image classification: A deep learning approach,” in *2018 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, 2018, pp. 2405–2412.
- [4] J. Zuluaga-Gomez, Z. Al Masry, K. Benaggoune, S. Meraghni, and N. Zerhouni, “A cnn-based methodology for breast cancer diagnosis using thermal images,” *Computer Methods in Biomechanics and Biomedical Engineering: Imaging & Visualization*, vol. 9, no. 2, pp. 131–145, 2021.
- [5] E.-K. Kim, H.-E. Kim, K. Han, B. joo Kang, Y.-M. Sohn, O. H. Woo, and C. W. Lee, “Applying data-driven imaging biomarker in mammography for breast cancer screening: Preliminary study,” *Scientific Reports*, vol. 8, 2018.
- [6] N. Dhungel, G. Carneiro, and A. P. Bradley, “Deep learning and structured prediction for the segmentation of mass in mammograms,” in *International Conference on Medical image computing and computer-assisted intervention*. Springer, 2015, pp. 605–612.
- [7] L. D. True, “Morphometric applications in anatomic pathology,” *Human pathology*, vol. 27, no. 5, pp. 450–467, 1996.
- [8] A. Esteva, B. Kuprel, R. A. Novoa, J. Ko, S. M. Swetter, H. M. Blau, and S. Thrun, “Dermatologist-level classification of skin cancer with deep neural networks,” *nature*, vol. 542, no. 7639, pp. 115–118, 2017.
- [9] J. Qin, W. Pan, X. Xiang, Y. Tan, and G. Hou, “A biological image classification method based on improved cnn,” *Ecological Informatics*, vol. 58, p. 101093, 2020. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1574954120300431>
- [10] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, “How transferable are features in deep neural networks?” *CoRR*, vol. abs/1411.1792, 2014. [Online]. Available: <http://arxiv.org/abs/1411.1792>

- [11] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto, and H. Adam, “Mobilenets: Efficient convolutional neural networks for mobile vision applications,” *CoRR*, vol. abs/1704.04861, 2017. [Online]. Available: <http://arxiv.org/abs/1704.04861>
- [12] F. A. Spanhol, L. S. Oliveira, C. Petitjean, and L. Heutte, “A dataset for breast cancer histopathological image classification,” *IEEE Transactions on Biomedical Engineering*, vol. 63, no. 7, pp. 1455–1462, 2016.
- [13] M. F. Mridha, M. A. Hamid, M. M. Monowar, A. J. Keya, A. Q. Ohi, M. R. Islam, and J.-M. Kim, “A comprehensive survey on deep-learning-based breast cancer diagnosis,” *Cancers*, vol. 13, no. 23, 2021. [Online]. Available: <https://www.mdpi.com/2072-6694/13/23/6116>